

통합 전처리 파이프라인을 활용한 멀티모달 가스 센서 데이터셋에서의 모델 성능 비교

맹영민^{0,1,2} 주진호^{1,2} 윤재훈^{1,2} 정우창^{1,2} 안홍렬^{1,2,*}
¹수원대학교 데이터과학부, ²수원대학교 DS&ML 센터

esg47034@gmail.com, wlsgh20728@naver.com, mark096750@naver.com, woochang4862@gmail.com,
hrahn@suwon.ac.kr

An Integrated Preprocessing Pipeline for Model Performance Comparison on a Multimodal Gas Sensor Dataset

Yeongmin Maeng^{0,1,2} Jinho Ju^{1,2} Jaehoon Yun^{1,2} Woochang Jeong^{1,2} Hongryul Ahn^{1,2,*}
¹Division of Data Science, ²DS&ML Center, The University of Suwon

요약

본 연구는 MultimodalGasData 데이터셋을 활용한 기존 연구들 간 전처리 과정의 불일치로 인해 발생한 재현성 문제를 해결하기 위해 표준화된 통합 전처리 파이프라인을 제안한다. 제안된 파이프라인은 통계적 이상치 탐지, 가스 분사 시점 식별, 정규화, 샘플링 과정을 포함하여 데이터의 일관성과 신뢰성을 확보한다. 동일한 전처리 절차를 적용한 데이터셋을 기반으로 기존의 주요 모델들을 비교한 결과, MultiTask Fusion 기반 모델이 가장 높은 예측 정확도를 보였다. 본 연구는 멀티모달 가스 탐지 분야에서 재현성과 객관적 성능 비교를 보장할 수 있는 표준화된 분석 기준을 제시한다는 의의가 있다.

1. 서론

가스 누출 탐지는 재난 대응, 산업 안전, 환경 보호를 위한 핵심 기술로, 실시간 위험 감지와 대응을 위해 정확하고 신뢰성 높은 인공지능 기반 탐지 시스템이 필요하다. 최근에는 가스 센서와 열화상 카메라를 결합한 멀티모달 접근이 주목받고 있으며, 이는 단일 센서의 한계를 보완해 탐지 정확도와 신뢰성을 높인다. MultimodalGasData는 4 종류의 가스 누출에 대해 센서 데이터와 열화상 이미지를 동시에 수집한 가스 누출 분야의 대표적 벤치마크 데이터셋으로 [1], 다양한 머신러닝·딥러닝 모델 연구에 활용되어 왔다[2-6].

그러나 Utomo et al.(2025)은 MultimodalGasData 데이터셋에 대한 기존 연구들 간에 전처리 방식의 불일치로 인해 성능 비교가 객관적이지 못하다는 점을 지적하였다[2]. 특히, 가스 종류에 따라 실험 환경과 센서 반응 범위가 다르기 때문에 적절한 스케일링이나 정규화 과정을 생략할 경우, 모델이 실제 가스 누출 여부가 아닌 단순한 스케일 차이에 반응할 가능성이 있다. 이러한 문제는 재현 가능한 실험 설계와 데이터 처리 표준의 부재에서 비롯된 것으로, 연구 간 신뢰성 확보를 위해 데이터 수집·처리·분석 과정의 명확한 문서화와 추적 가능성이 필요하다고 보고하였다.

본 연구는 이러한 한계를 해결하고 MultimodalGasData의 분석 신뢰성을 높이기 위해 4 단계 통합 전처리 파이프라인을 제안한다. 제안된 파이프라인은 (1) 센서 신호 변화로 가스 분사 구간을 식별하고, (2) 이상 구간을 제거하며, (3) Min-max 정규화로 센서 간 스케일 차이를 보정하고, (4) 데이터를 80:20으로 분할해 교차검증용 학습·평가 세트를 구성한다. 이를 통해 다양한 인공지능 모델을 동일 조건에서 공정하게 비교할 수 있으며, 멀티모달 가스 탐지 연구의 재현성과 객관성을 강화한다.

2. MultimodalGasData 데이터셋

MultimodalGasData는 가스 센서 데이터와 열화상 이미지를 결합한 멀티모달 가스 탐지 벤치마크 데이터셋이다. 첫번째 모달리티는 7종의 가스 센서(MQ2, MQ3, MQ5, MQ6, MQ7, MQ8, MQ135)가 측정하는 시계열 센싱 데이터이며, 두번째 모달리티는 열화상 카메라가 -40~330℃ 범위의 온도에 대해 206×156 픽셀 해상도로 측정하는 이미지 데이터이다. 이 모달리티 측정 장비를 통해 4개의 가스 종류 NoGas(control gas), Perfume, Smoke, Mixture에 대해 15초, 30초, 45초 간격으로 가스를 배출하며 2초 간격으로 1600개 샘플링을 통해 데이터를 측정하였다. 센서 값과 열화상 이미지는 시간 동기화된 쌍으로 제공된다. 그림 1은 해당 데이터셋의 수집 프로세스를 보여준다.




그림 1. MultimodalGasData 데이터 수집 프로세스 [1]




그림 2. 데이터 전처리 프로세스. Mixture 가스 종류에 대한 예시로 다른 종류 가스도 동일하게 진행된다.

3. 관련연구

MultimodalGasData 데이터셋을 활용한 최근 연구들은 네 가지 주요 접근법으로 분류된다.

생성 모델 기반 접근법은 SRGAN 으로 열화상 이미지 해상도를 향상시키고 Sparse Autoencoder 로 센서 데이터의 잠재 특징을 추출하여 멀티모달 데이터 품질을 개선하였다[3].

설명 가능한 AI 기반 접근법은 XAI 기법과 데이터 거버넌스를 결합하여 모델 예측의 해석 가능성과 신뢰성을 확보하였으며[2], ExAIRFC-GSDC 프레임워크는 Random Forest 와 XAI 를 결합한 해석 가능한 탐지 시스템을 구축하였다[4].

멀티태스크 학습 접근법은 가스 탐지와 분류를 동시 학습하며, E-nose 센서와 열화상 데이터를 융합한 딥러닝 파이프라인으로 태스크 간 지식 공유를 통해 성능을 향상시켰다[5].

트리 모델 분류기 접근법은 XAI 로 추출한 열화상 특징과 수치 데이터를 IDFC 분류기에 입력하여 정확한 분류 시스템을 구축하였다[6].

그러나 모든 연구가 같은 데이터셋과 멀티모달 융합을 사용하면서도, 전처리 방법 불일치로 인해 동일 조건 비교가 불가능하고 재현성이 부족하여 공정한 성능 비교가 어렵다[2]. 이는 표준화된 전처리 파이프라인의 필요성을 제기한다.

4. 방법

4.1 통합 데이터 전처리 파이프라인

기존 연구들은 가스 분사 시점 정의가 불명확하고 전처리 기준이 연구마다 달라 재현성과 객관적 비교가 어려웠다. 본 연구에서는 이를 해결하기 위해 4 단계 통합 전처리 파이프라인을 제안한다 (그림 2).

[STEP1] 센서 신호 데이터를 기준으로, 측정 값의 급격한 변화 지점을 탐지하여 가스 분사 시작점과 종료점을 명확히 정의하고 모든 샘플을 동일 구간으로 정렬한다.

[STEP2] 가스 분출 구간 중에서 이상 구간은 제외한다. (이상 구간은 센서 파형 시각화를 통해 정상 반응 패턴에서 벗어난 영역으로 정의하며, 센서 값의 비정상적 급변을 기준으로 판단한다. 이러한 제거 과정은 학습 왜곡을 방지하고, 가스별 반응 패턴의 일관성을 유지하는 데 목적이 있다.)

[STEP3] Min-max 정규화로 센서 반응의 절대값 차이를 제거하여 상대적 패턴 학습을 가능하게 한다.

[STEP4] 구간을 80/20 으로 분할하여 훈련·테스트 세트를 구성하고 각 구간에서 10 개 샘플을 무작위 추출한다. 20 회 반복하여 교차검증용 데이터셋 20 세트를 생성한다. LSTM 전용 시계열 데이터셋을 위해 각 샘플 포인트의 전후 5 개 시점을 포함한 11 개 시점 윈도우를 구성하여 시간적 의존성 학습을 지원한다.

4.2 비교 실험

제안된 전처리 파이프라인을 기반으로 여러 모델의 성능 비교 실험을 수행하였다. 비교 모델은 MultimodalGasData 에 대한 기존 연구에서 사용한 모델들로,

모델	Accuracy	Precision	Recall	F1-Score	AUROC
MT-Fusion (E+D+C)	0.978	0.978	0.978	0.978	0.999
MT-Fusion (R+I+M)	0.922	0.939	0.922	0.922	0.999
CNN+LDA	0.900	0.910	0.920	0.920	0.980
MM-Early (CNN+LSTM)	0.865	0.878	0.887	0.880	0.976
LSTM	0.848	0.872	0.870	0.871	0.965
CNN	0.847	0.879	0.868	0.868	0.970
IDFC	0.810	0.840	0.840	0.830	0.920
Random Forest	0.756	0.772	0.756	0.757	0.919

표 1. 모델 별 성능 지표 비교.

굵은 글씨는 해당 지표에서 최고 순위를 가리킨다




그림 3. 모델 별 성능 지표 비교 시각화

① MT-Fusion (E+D+C)[5], ② MT-Fusion (R+I+M)[5], ③ CNN+LDA[3], ④ MM-Early (CNN+LSTM)[1], ⑤ LSTM[1], ⑥ CNN[1], ⑦ IDFC[6], ⑧ Random Forest[4]의 총 8 종 모델을 사용하였다. 성능은 Accuracy, Precision, Recall, F1-score, AUROC 를 지표로 평가하였다. 또한 20 회 교차검증 반복 실험 후 평균 계산 하여 일반성을 확보하였다. 비교 실험 환경은 Ubuntu 20.04.6 LTS 기반으로, AMD Ryzen Threadripper 3990X(64 코어, 128 스레드), 251GB RAM, NVIDIA RTX 3090 GPU 2 개(각 24GB), CUDA 12.5 를 사용하였다.

5. 실험 및 결과

8 개 모델의 성능 비교 결과, MultiTask Fusion 기반 모델이 최고 성능을 기록하였다(표 1, 그림 3). EfficientNet, DenseNet, ConvNeXt 조합은 Accuracy 와 F1-score 모두

0.9778 로 1 위를, ResNet, Inception, MobileNet 조합은 0.9222 로 2 위를 달성하였다.

CNN+LDA 모델은 Accuracy 0.90 과 높은 AUROC(0.98)을 기록하며 3 위를 차지하였다. Multimodal Early Fusion(0.8649), CNN(0.8473), LSTM(0.8484)은 중간 수준의 성능을 보였으며, IDFC(0.8100)와 Random Forest(0.7556)는 상대적으로 낮은 성능을 나타냈다.

MultiTask Fusion 두 모델만 90% 이상의 정확도를 달성하여, 단일 신경망 및 전통적 머신러닝 모델과 뚜렷한 성능 차이를 보였다.

6. 토의

MultiTask Fusion 과 CNN+LDA 의 우수한 성능은 멀티 백본 융합 구조와 선형 판별 기반 피쳐 보강이 센서 및 열화상 데이터의 상호보완적 정보를 효과적으로 통합했기 때문으로 분석된다. 특히 MultiTask Fusion 은 서로 다른 CNN 구조의 특성을 결합하여 가스 종류별 미세한 반응 차이를 정밀하게 포착할 수 있었다.

7. 참고문헌

[1] P. Narkhede, R. Walambe, P. Chandel, S. Mandaokar, & K. Kotecha, "MultimodalGasData: Multimodal dataset for gas detection and classification," *Data*, vol. 7, no. 8, p. 112, 2022.

[2] S. Utomo, A. Pratap, P. Karthikeyan, J. Ayeelyan, H.-C. Hsu, & P.-A. Hsiung, "When explainable artificial intelligence meets data governance: Enhancing trustworthiness in multimodal gas classification," *Information Fusion*, vol. 125, p. 103440, 2026.

[3] P. Jadhav, S. Vuppala Adithya, N. Bhojane, A. Singh, S. Gite, B. Pradhan, M. Bachute, & A. Alamri, "Multimodal gas detection using E-nose and thermal images: An approach utilizing SRGAN and Sparse Autoencoder," *CMC-COMPUTERS, MATERIALS & CONTINUA*, vol. 83, no. 2, pp. 3493-3517, 2025.

[4] B. Lalithadevi & S. Krishnaveni, "ExAIRFCGSDC: An advanced machine learning-based interpretable framework for accurate gas leakage detection and classification," *International Journal of Computational Intelligence Systems*, vol. 18, no. 1, pp. 16-28, 2025.

[5] O. Attallah, "Multitask deep learning-based pipeline for gas leakage detection via E-nose and thermal imaging multimodal fusion," *Chemosensors*, vol. 11, no. 7, p. 364, 2023.

[6] E. Zhang & E. Zhang, "Gas pipeline leakage detection based on multiple multimodal deep feature selections and optimized deep forest classifier," *Frontiers in Environmental Science*, vol. 13, p. 1569621, 2025.