


この論文では、まず、このデータセットの構成、収集方法、および評価方法を詳しく説明する。次に、MultimodalGasDataの4つの主要な特徴を詳しく説明する。最後に、このデータセットの価値と今後の研究の方向性を示す。

まず、Utomo et al.(2025) が MultimodalGasData データセットの構成と収集方法を詳しく説明する。このデータセットは、7種類のガス（MQ2, MQ3, MQ5, MQ6, MQ7, MQ8, MQ135）と、NoGas（control gas）、Perfume、Smoke、Mixture の4種類のガスを含む。収集方法は、まずガスを放出し、その後安定化を待つ。このプロセスを15-20回繰り返す。収集されたデータは、80:20の割合でトレーニングデータとテストデータに分割される。

次に、MultimodalGasDataの4つの主要な特徴を詳しく説明する。1) データの多模态性: このデータセットは、ガス濃度の測定値と、そのガスの種類を識別するための画像データを含む。2) データの多様性: このデータセットは、7種類のガスと、NoGas、Perfume、Smoke、Mixture の4種類のガスを収録している。3) データの時間的連続性: このデータセットは、ガスの放出と安定化の過程を記録している。4) データの高精度: このデータセットは、80:20の割合でトレーニングデータとテストデータに分割されている。

2. MultimodalGasData の構成

MultimodalGasDataの構成は、まずガスを放出し、その後安定化を待つ。このプロセスを15-20回繰り返す。収集されたデータは、80:20の割合でトレーニングデータとテストデータに分割される。このデータセットは、7種類のガス（MQ2, MQ3, MQ5, MQ6, MQ7, MQ8, MQ135）と、NoGas（control gas）、Perfume、Smoke、Mixture の4種類のガスを含む。収集方法は、まずガスを放出し、その後安定化を待つ。このプロセスを15-20回繰り返す。収集されたデータは、80:20の割合でトレーニングデータとテストデータに分割される。



1. MultimodalGasDataの構成 [1]

2. データの多模态性. Mixture のデータは、ガスの種類と濃度の両方を測定している。

MultimodalGasData データセットの価値と今後の研究の方向性を示す。

この論文では、SRGANを用いて、ガスの種類と濃度を高精度で識別するためのモデルを提案する。このモデルは、Sparse Autoencoderを用いて、ガスの種類と濃度を高精度で識別する。

本文提出的 AI 模型 XAI 模型能够解释模型决策过程，并能够解释模型决策过程[2]，ExAIRFC-GSDC 模型能够解释 Random Forest 模型 XAI 模型决策过程[4]。

本文提出的模型能够解释模型决策过程，E-nose 模型能够解释模型决策过程[5]。

本文提出的模型 XAI 模型能够解释模型决策过程 IDFC 模型能够解释模型决策过程[6]。

本文提出的模型能够解释模型决策过程，本文提出的模型能够解释模型决策过程[2]。本文提出的模型能够解释模型决策过程。

4. 实验

4.1 实验环境

本文实验环境为 Windows 10 操作系统，Python 3.7 版本，TensorFlow 2.2 版本。实验数据集为 4 类数据集（图 2）。

[STEP1] 本文实验环境为 Windows 10 操作系统，Python 3.7 版本，TensorFlow 2.2 版本。实验数据集为 4 类数据集（图 2）。

[STEP2] 本文实验环境为 Windows 10 操作系统，Python 3.7 版本，TensorFlow 2.2 版本。

(本文实验环境为 Windows 10 操作系统，Python 3.7 版本，TensorFlow 2.2 版本。实验数据集为 4 类数据集（图 2）。)

[STEP3] Min-max 归一化模型能够解释模型决策过程。

[STEP4] 本文 80/20 数据集模型能够解释模型决策过程。本文 10 类数据集模型能够解释模型决策过程。20 类数据集模型能够解释模型决策过程。LSTM 模型能够解释模型决策过程。5 类数据集模型 11 类数据集模型能够解释模型决策过程。

4.2 实验结果

本文实验环境为 Windows 10 操作系统，Python 3.7 版本，TensorFlow 2.2 版本。实验数据集为 4 类数据集（图 2）。MultimodalGasData 模型能够解释模型决策过程。

模型	Accuracy	Precision	Recall	F1-Score	AUROC
MT-Fusion (E+D+C)	0.978	0.978	0.978	0.978	0.999
MT-Fusion (R+I+M)	0.922	0.939	0.922	0.922	0.999
CNN+LDA	0.900	0.910	0.920	0.920	0.980
MM-Early (CNN+LSTM)	0.865	0.878	0.887	0.880	0.976
LSTM	0.848	0.872	0.870	0.871	0.965
CNN	0.847	0.879	0.868	0.868	0.970
IDFC	0.810	0.840	0.840	0.830	0.920

[4] B. Lalithadevi & S. Krishnaveni, "ExAIRFCGSDC: An advanced machine learning-based interpretable framework for accurate gas leakage detection and classification," *International Journal of Computational Intelligence Systems*, vol. 18, no. 1, pp. 16–28, 2025.

[5] O. Attallah, "Multitask deep learning-based pipeline for gas leakage detection via E-nose and thermal imaging multimodal fusion," *Chemosensors*, vol. 11, no. 7, p. 364, 2023.

[6] E. Zhang & E. Zhang, "Gas pipeline leakage detection based on multiple multimodal deep feature selections and optimized deep forest classifier," *Frontiers in Environmental Science*, vol. 13, p. 1569621, 2025.